Caso práctico: ¿Quién va a cancelar Netflix?

Netflix es una plataforma de streaming que opera en seis países de Latinoamérica. En los últimos meses la gerencia ha notado que muchos suscriptores cancelan su cuenta, y cada cancelación es dinero que se pierde. Por eso les entrega una base con 5 025 usuarios y su comportamiento del último mes, para que descubran qué perfil tienen los usuarios que cancelan y construyan un modelo que prediga si un usuario va a cancelar (variable cancelo).

NOTA: la base viene tal como sale del sistema, con registros duplicados, valores vacíos, edades imposibles, horas negativas y planes escritos de forma inconsistente. Limpiarla es parte del trabajo.

Variables del dataset

id_usuario, fecha_registro, edad, genero, pais, plan (Básico, Estándar, Premium), precio_mensual_soles, meses_suscrito, metodo_pago, dispositivo_principal, perfiles_activos, genero_favorito, horas_vistas_mes, dias_desde_ultimo_acceso, titulos_completados_mes, calificacion_promedio (1 a 5), tickets_soporte, usa_descargas, pct_vistas_por_recomendacion y cancelo (Sí/No, variable objetivo).

Ejecutar:

1. **Limpieza:** detectar y tratar duplicados, nulos, valores fuera de rango e inconsistencias de texto. Justificar cada decisión (eliminar o imputar).
2. **Análisis exploratorio:** calcular la tasa de cancelación general y por plan, país, método de pago y dispositivo. Comparar el comportamiento de quienes cancelan y quienes no (horas vistas, días sin entrar, calificación, tickets). Elaborar al menos 5 gráficos que cuenten algo, no solo que decoren.
3. **Modelo predictivo:** entrenar como mínimo dos modelos de clasificación de la librería scikit-learn (por ejemplo, LogisticRegression y RandomForestClassifier), separando 75 % de los datos para entrenamiento y 25 % para prueba.
4. **Evaluación:** comparar los modelos con exactitud, precisión, recall, F1 y matriz de confusión. Explicar por qué la exactitud sola puede engañar en este caso.
5. **Variables importantes:** identificar qué factores pesan más en la cancelación.
6. **Conclusiones y recomendaciones:** redactar 3 a 5 hallazgos y proponer acciones concretas que Netflix podría tomar para retener usuarios.

Librerías sugeridas

pandas y numpy para manipular los datos, matplotlib y seaborn para los gráficos, y scikit-learn para construir y evaluar los modelos (train_test_split, classification_report, confusion_matrix). Pueden trabajar en Visual studio o con Google Colab.

Entregables

El notebook (.ipynb) con el código comentado y una presentación de máximo 10 diapositivas dirigida a la gerencia, es decir, en lenguaje de negocio y sin mostrar código.

DESCARGA AQUÍ LA DATA